

corrections.log 有 20+ 条了——然后呢？

原料 · corrections

- 没加 confidence 字段
- 不处理图片太大
- 跳过 EVALUATE
- AC 写成「体验好」
- 没参考 TECH.md
- 只测 happy path ...

蒸馏 漏斗

产品 · principles

- P · 每个 API 输出必须满足 schema 全部必填字段
- P · 完成 = 主动尝试破坏且失败

行数变少，覆盖变广。

三个动作，反复做



上提

Rules → Principle

信号

3+ 条 rules 追溯到同一根因

动作

写一条覆盖整类的 principle，退休这些 rules 到 _retired/

验证

新 principle 能否覆盖未来同类问题？



下沉

Rule → Gate 后退休

信号

某条 rule 被违反 3+ 次，每次同一形式

动作

做成代码级 gate（机械阻断），退休 prose rule

验证

gate 存在后这条 rule 再也不需要了吗？



毕业

Gate 不再触发 → 移除

信号

gate 连续 30 天 / 10 次运行未触发

动作

移入 _graduated/（留证据，不删除）

验证

上游够强则 gate 多余——渐进毕业

没有第四招。上提、下沉、毕业——每招都有明确触发信号，不靠感觉。

Step 1 — 看 corrections, 找 cluster

蒸馏第一步不是写 principle —— 是找 pattern。给每条 correction 打标签、分组、数数。

corrections.log

```
[D1] 没加 confidence 字段      → 格式遗漏
[D1] 不处理图片太大            → 深度不足
[D2] 跳过 EVALUATE 写代码      → 流程跳步
[D2] AC 写成「体验好」         → 深度不足
[D2] 没参考 TECH.md 的 ADR     → 引用缺失
[D2] 错误响应没 error_code     → 格式遗漏
[D2] 没考虑 Bedrock 限流       → 深度不足
[D2] 测试只测 happy path       → 深度不足
```

分组：格式遗漏 2 · 流程跳步 1 · 引用缺失 1
深度不足 4 ← 蒸馏候选！

1 · 标签

每条标「关于什么」：格式遗漏 / 深度不足 / 流程跳步 / 引用缺失

2 · 分组

数每组几条，粗粒度即可

3 · 候选

≥ 3 条的组 = 蒸馏候选

这一步不需要 AI —— 是人的判断：表面不同的 correction 背后是不是同一个根因？

动手：25 分钟，governance 变短

Step 1 · Pattern 识别

8 min

- 打开 corrections.log
- 打标签分组
- 找 ≥ 3 条 cluster
- 写一句话根因

Step 2 · 执行蒸馏

12 min

- cluster + rules 存在 → 上提
- rule 反复违反 → 下沉为 gate
- gate 从未触发 → 标记毕业

Step 3 · 验证

5 min

- 行数减少了? ☒
- eval coverage 没降? ☒
- 退休有 _retired/ 记录? ☒

蒸馏前快照

```
wc -l governance/principles.md governance/rules/*.md | tail -1
```

```
# ... 执行蒸馏: 编辑 principles.md / 移 rules 到 _retired/ / 建 gate
```

蒸馏后快照 (应更短)

```
wc -l governance/principles.md governance/rules/*.md | tail -1
```

判断辅助

找不到 cluster → corrections 还不够, 回去积累
principle 已存在仍违反 → 改措辞更锋利, 不加 rule

不确定能否合并 → 保守: 先不合并

corrections < 5 条的学员: 用讲师提供的「参考 corrections 集」练习蒸馏动作。

蒸馏前 vs 蒸馏后——展示你的差异

指标	首次蒸馏典型结果
governance 总行数	减少 10–30%
退休的 rules	2–4 条 → _retired/
principles 变化	5 条 → 4 条（或 3 条更强 / 不变但措辞更精准）
eval coverage score	不降

蒸馏 = 加一退多

加了 principle 但旧 rules 还在 = 积累，不是蒸馏。课后节奏：每 10–15 条新 corrections 做一次（约两周）。

「合并不了——每条都不一样」

→ 标签粒度太细，用更抽象的维度重新分组

「principle 已覆盖但 agent 还犯」

→ (1) 措辞不可判定 → 改硬 (2) 需要 gate 兜底

「蒸馏后 eval score 降了」

→ 过度合并 —— 回退，更保守地合并

蒸馏 = 课程的核心肌肉



上提

3+ 同类 correction



下沉

3+ 次违反



毕业

长期未触发

验证：行数减少 + coverage 不降 + 退休有记录 · 节奏：每 10–15 条 corrections 一次

做减法是反人性的。所以它是技能，不是本能。

NEXT ▶ Loop Engineering —— 现在系统精炼了，让它自动跑起来。